ANALYSE DES VENTES D'UNE LIBRAIRIE AVEC PYTHON

SOMMAIRE

1. Préparation des données
2. Analyse des différents indicateurs de vente
3. Tops et flops
4. Profil des clients
5. Tests statistiques
6. Conclusion

1. PRÉPARATION DES DONNÉES

Origine des données

- customers.csv
- products.csv
- transactions.csv

Fichier	Colonnes	Nb valeurs
customers.csv	client_id, sex, birth	8623
products.csv	id_prod, price, categ	3287
transactions.csv	id_prod, date, session_id, client_id	679532

1. JONCTION DES FICHIERS EN UN SEUL DATAFRAME LAPAGE

	id_prod	date	session_id	client_id	price	categ	sex	birth
0	0_1518	2022-05-20 13:21:29.043970	s_211425	c_103	4.18	0.0	f	1986
1	1_251	2022-02-02 07:55:19.149409	s_158752	c_8534	15.99	1.0	m	1988
2	0_1277	2022-06-18 15:44:33.155329	s_225667	c_6714	7.99	0.0	f	1968
3	2_209	2021-06-24 04:19:29.835891	s_52962	c_6941	69.99	2.0	m	2000
4	0_1509	2023-01-11 08:22:08.194479	s_325227	c_4232	4.99	0.0	m	1980

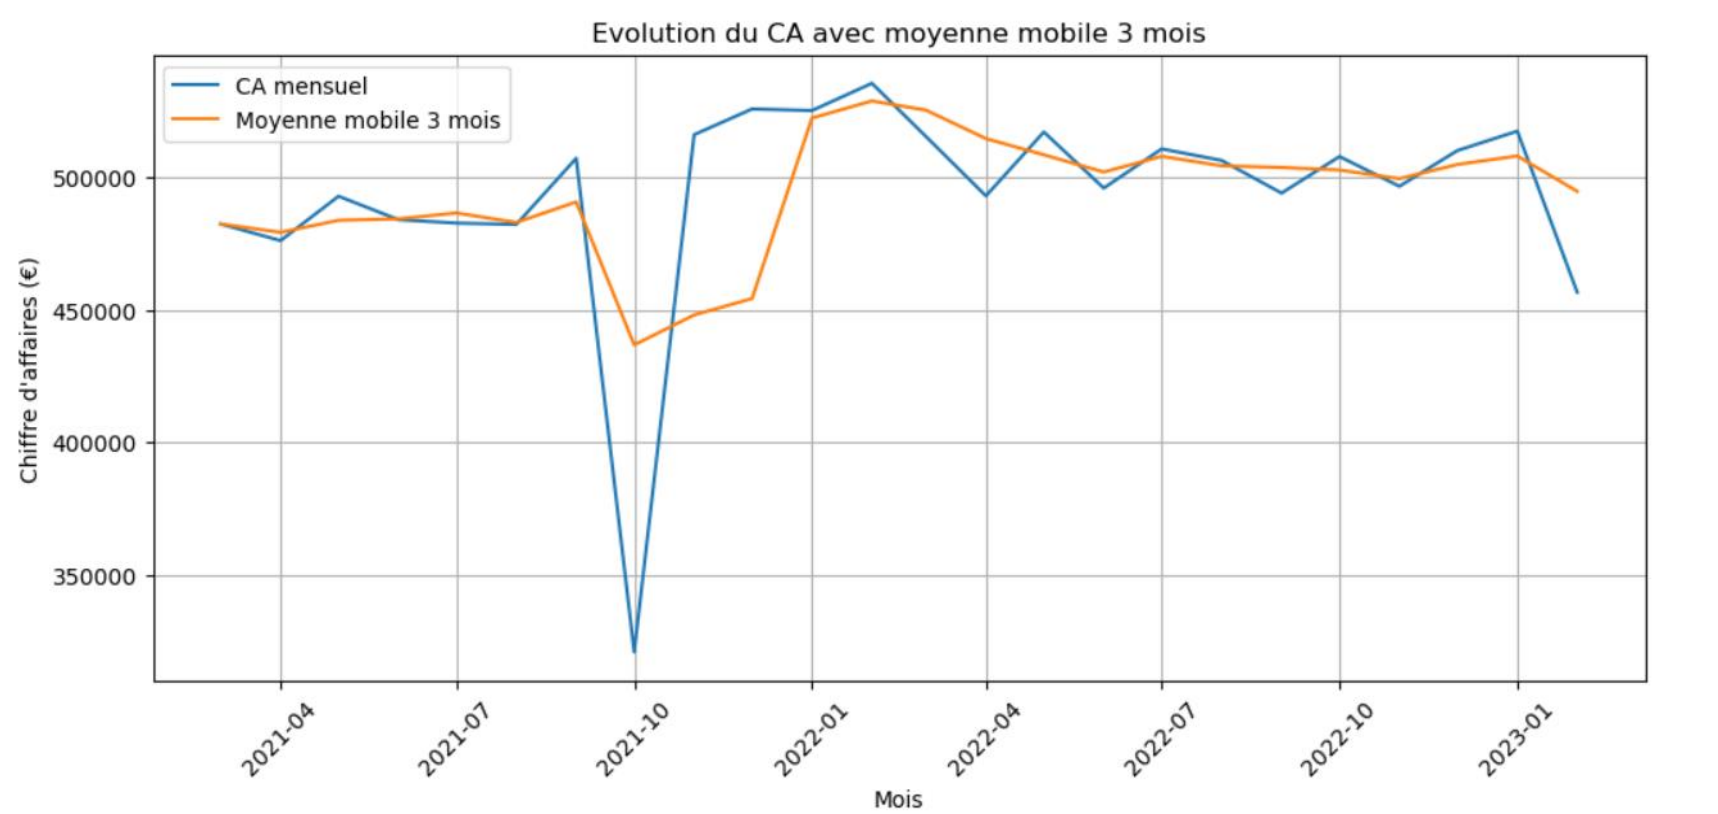
	date	price	categ	birth	age
count	679332	679332.000000	679332.000000	679332.000000	679332.000000
mean	2022-03-03 15:13:19.307389696	17.452345	0.441809	1977.811139	43.859363
min	2021-03-01 00:01:07.843138	0.620000	0.000000	1929.000000	17.000000
25%	2021-09-08 09:14:25.055994368	8.870000	0.000000	1970.000000	35.000000
50%	2022-03-03 07:50:20.817730560	13.990000	0.000000	1980.000000	42.000000
75%	2022-08-30 23:57:08.555173888	18.990000	1.000000	1987.000000	51.000000
max	2023-02-28 23:58:30.792755	300.000000	2.000000	2004.000000	94.000000
std	NaN	18.326510	0.594998	13.574553	13.590215

Les fichiers ont été joints via les clés client_id et id_prod pour créer un DataFrame unifié "lapage".

Le prix moyen des produits est de **17,45€**, avec un écart-type élevé (18,33€), ce qui suggère une grande variabilité des prix.

L'âge moyen des clients est de **43,86 ans**, avec un minimum de 17 ans et un maximum de 94 ans.

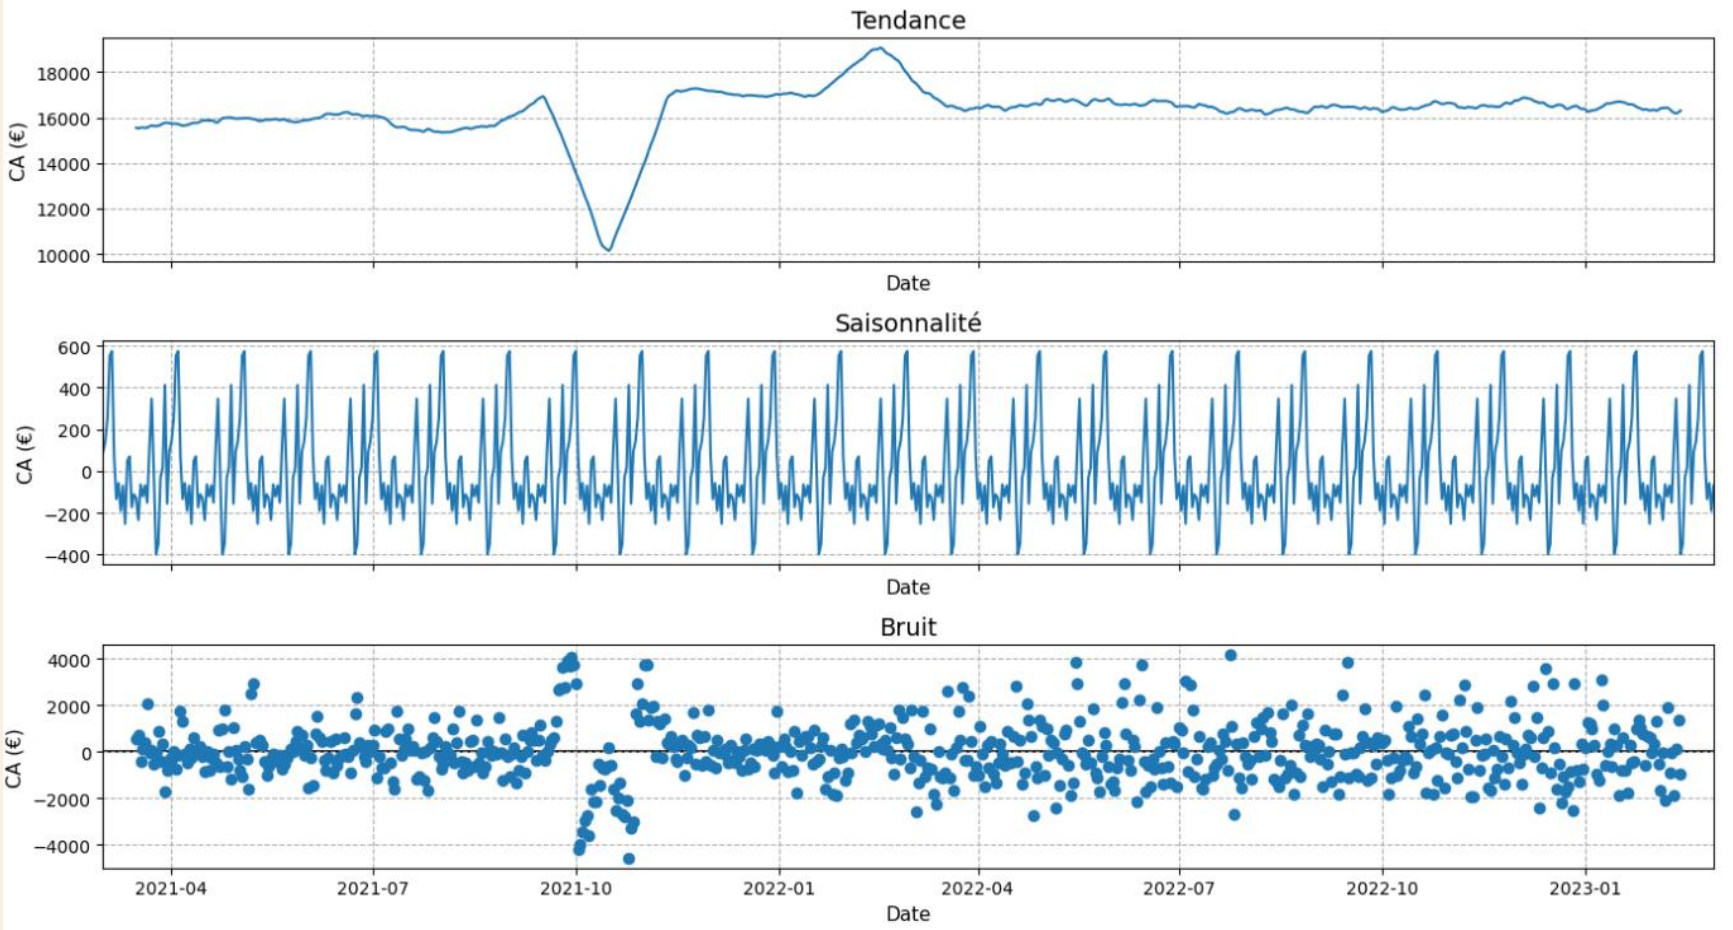
2. ANALYSE DES DIFFÉRENTS INDICATEURS DE VENTE



La moyenne mobile montre une tendance à la hausse jusqu'en 2022, puis une stabilisation voire une légère baisse.

Une baisse brutale est observable en octobre 2021. Cela necessitera une investigation.

2. ANALYSE DES DIFFÉRENTS INDICATEURS DE VENTE

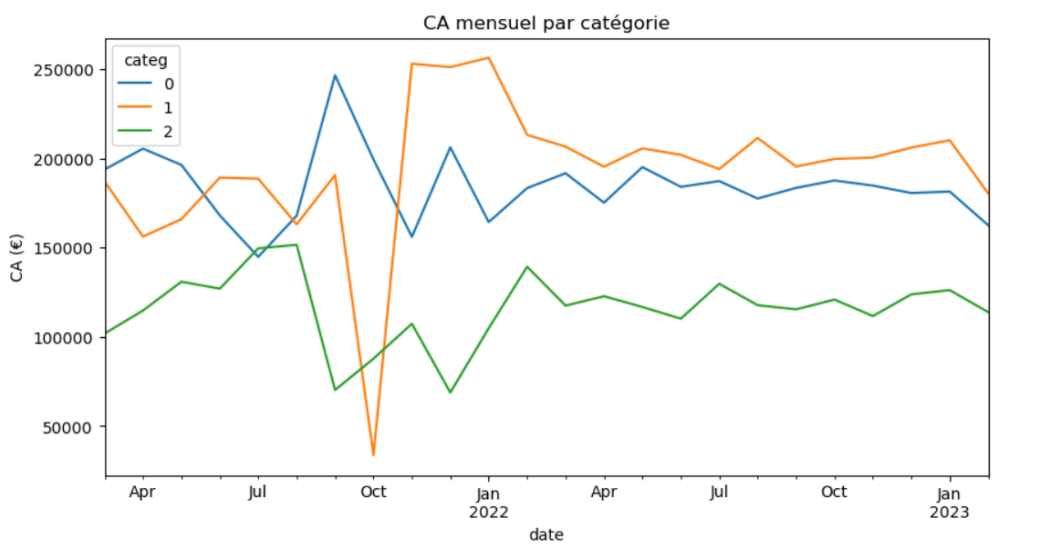


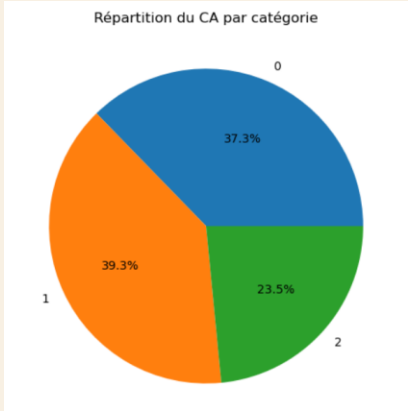
Croissance régulière du CA jusqu'à mi-2022, puis un plateau.

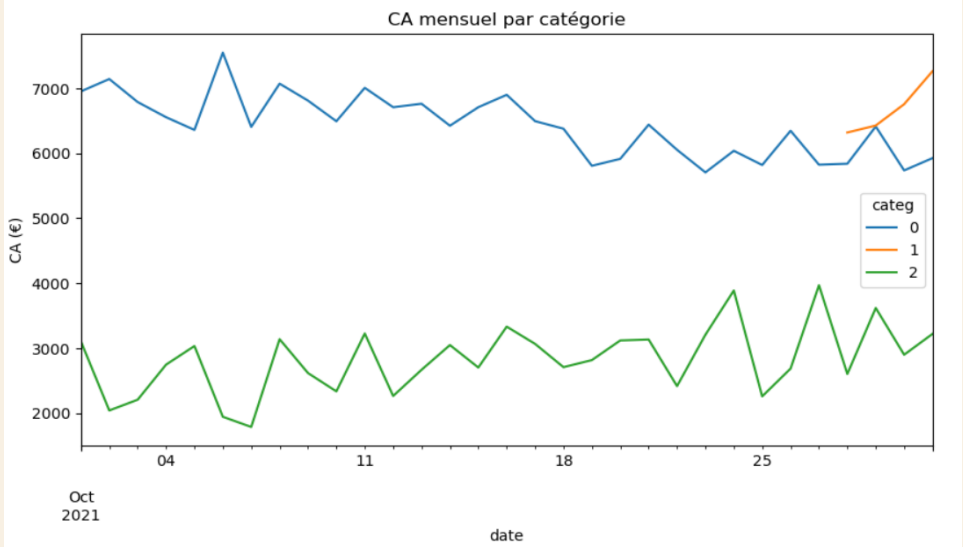
Il y a une saisonnalité mensuelle stable.

La baisse d'octobre 2021 est bien un évènement exceptionnel.

2. ANALYSE DES DIFFÉRENTS INDICATEURS DE VENTE



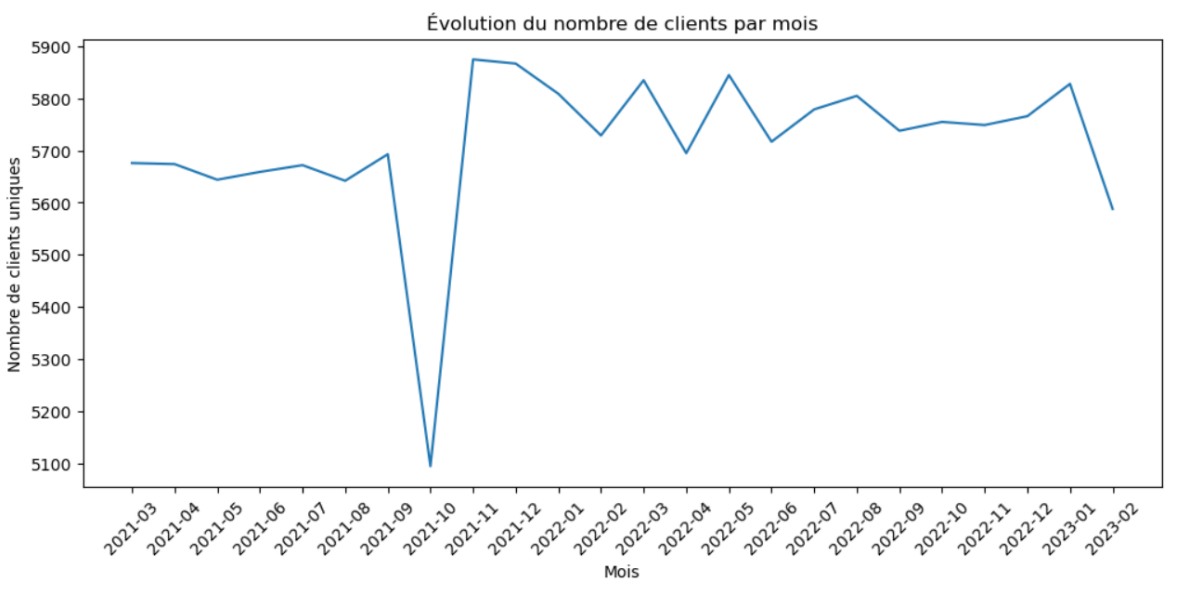


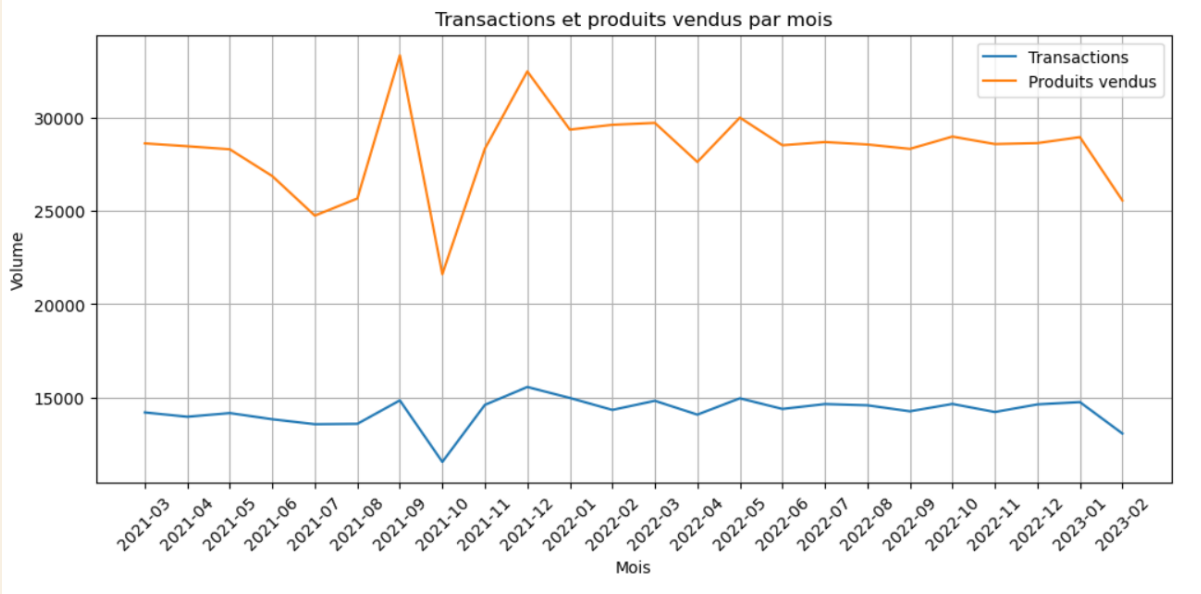


Les catégories contribuent différemment au chiffre d'affaires :

- La catégorie 2 est la moins rentable,
- Durant la deuxième partie du graphique (plateau), les 3 catégories suivent la même tendance,
- L'anomalie d'octobre 2021 provient du fait que les produits de catégorie 1 n'étaient pas vendus.

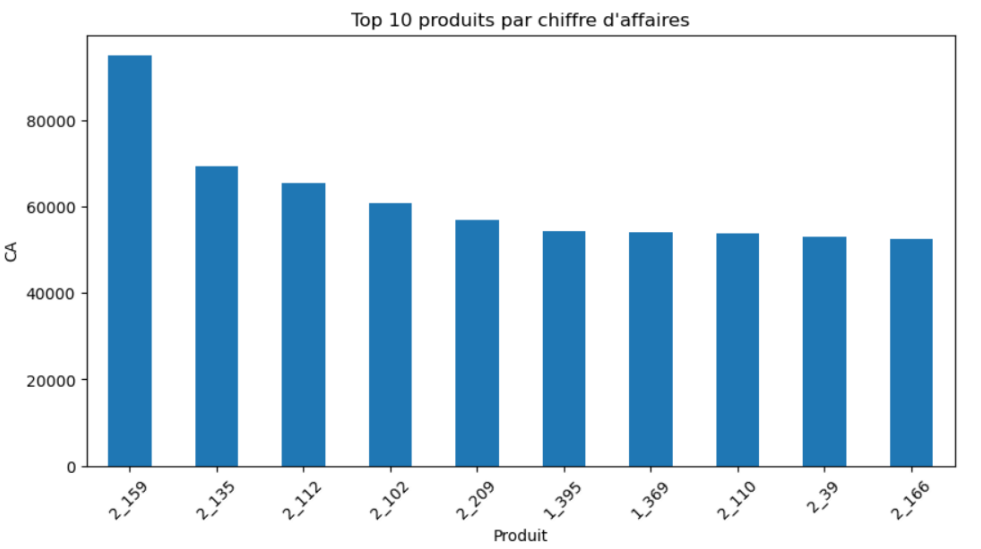
2. ANALYSE DES DIFFÉRENTS INDICATEURS DE VENTE



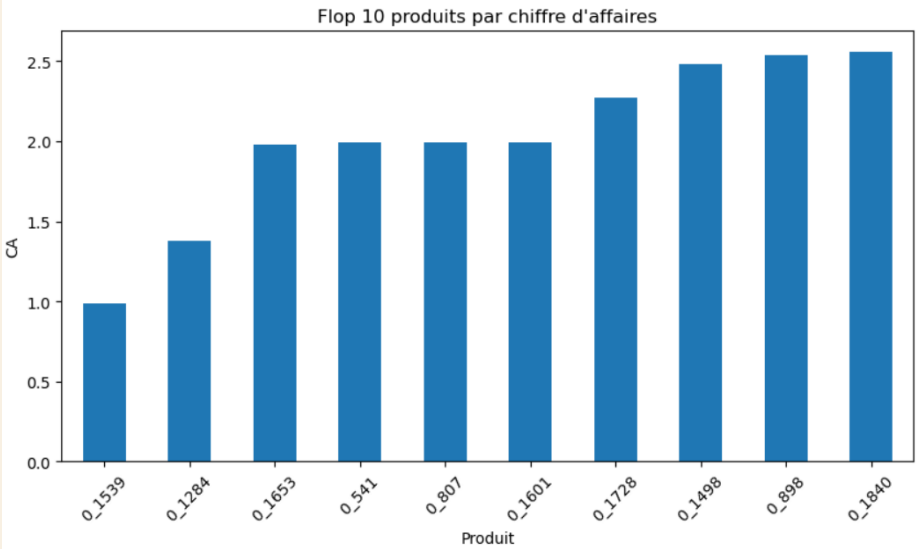


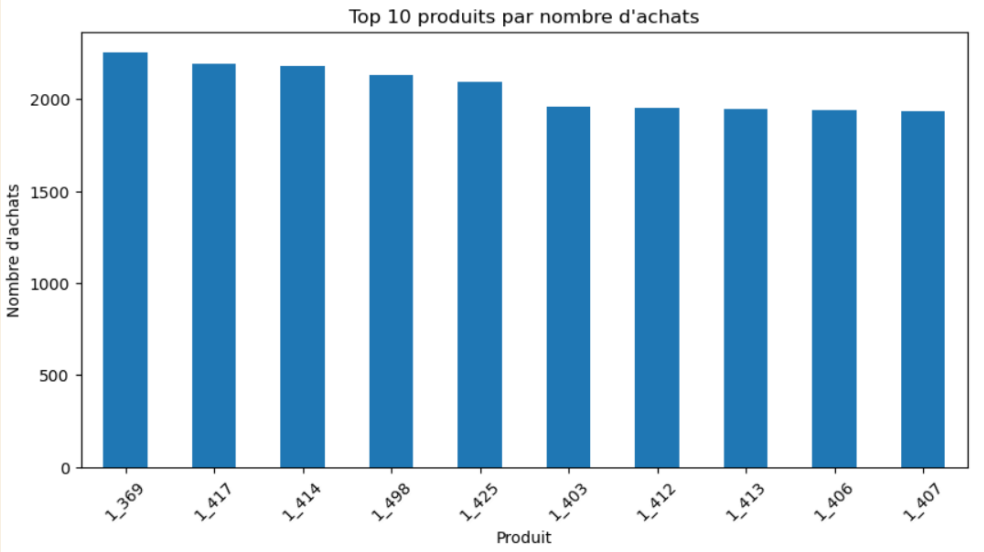
Le nombre de clients suit la logique du CA, y compris avec l'anomalie d'octobre 2021.
Tout comme le nombre de transactions et de produits vendus.

3. TOPS ET FLOPS

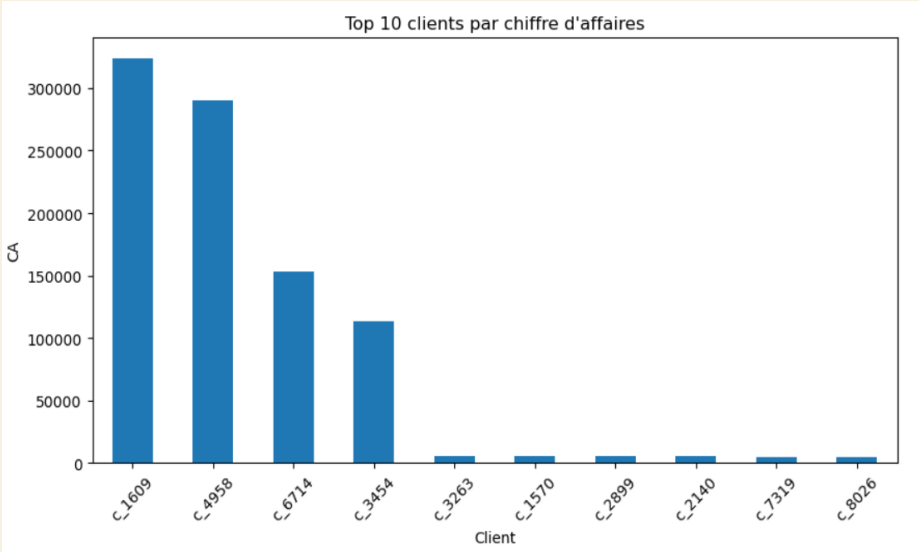


Quelques références concentrent une part importante du chiffre d'affaires, alors que certains produits ne se vendent presque pas.

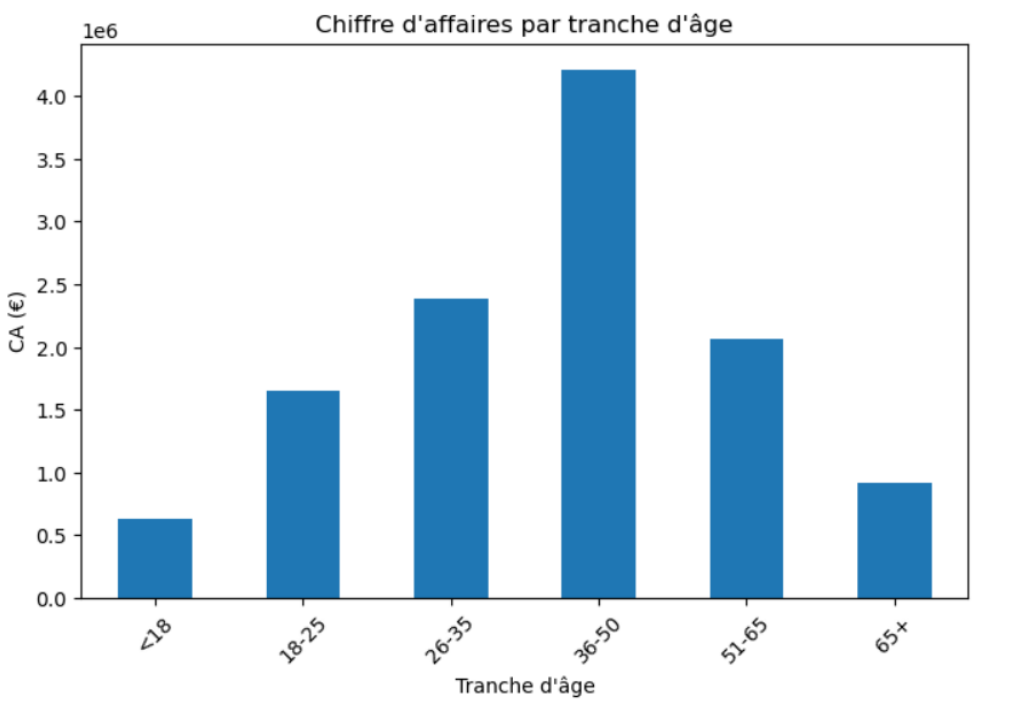


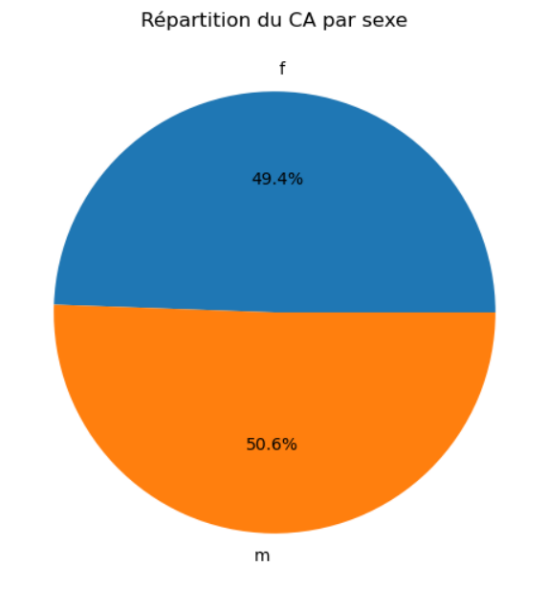


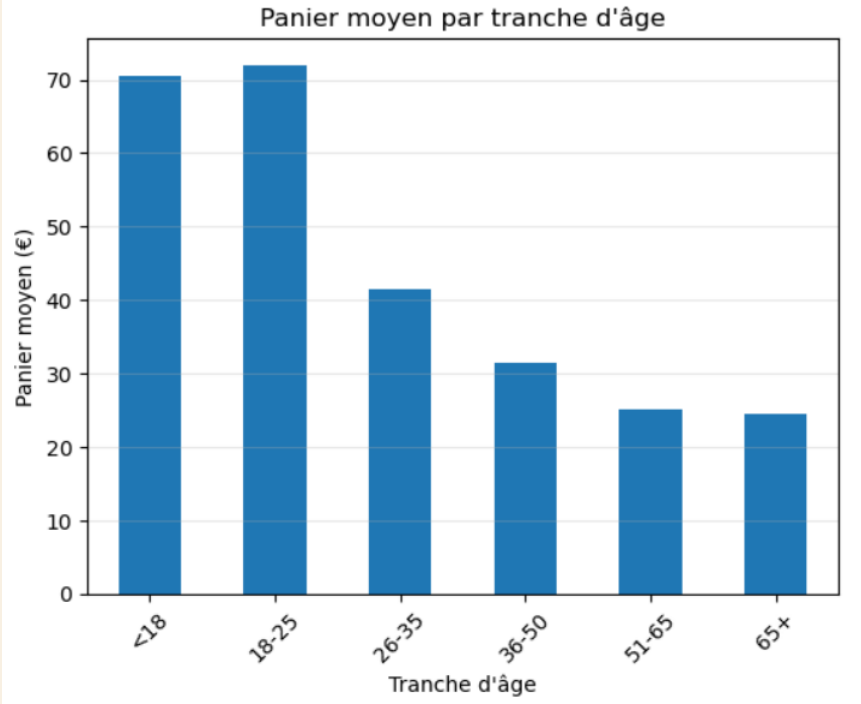
Quatre clients sont à l'origine d'une partie très importante du CA : Quatre clients B2B.



4. PROFIL DES CLIENTS

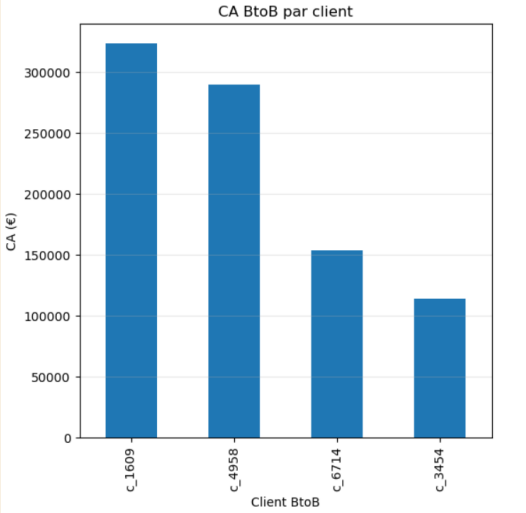




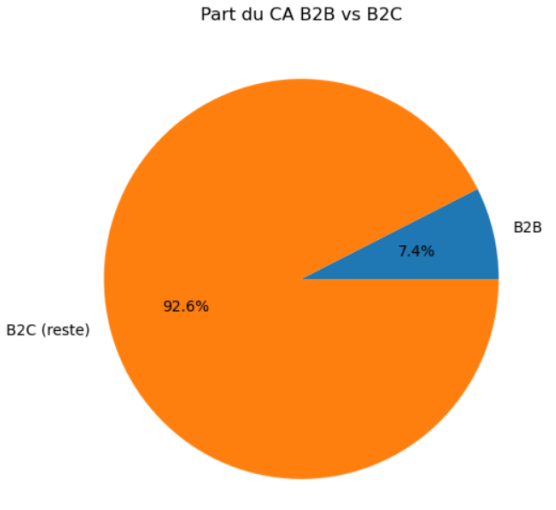


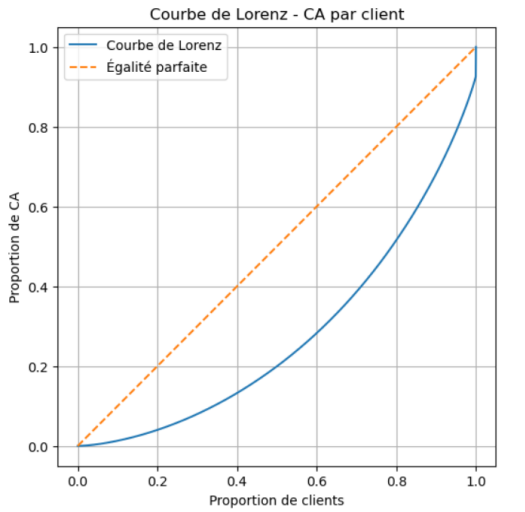
Les 36-50 ans sont responsables de la part la plus importante du CA.
Cependant, ce sont les jeunes (<18 ans, 18-25 ans), qui dépensent le plus par panier.

4. PROFIL DES CLIENTS

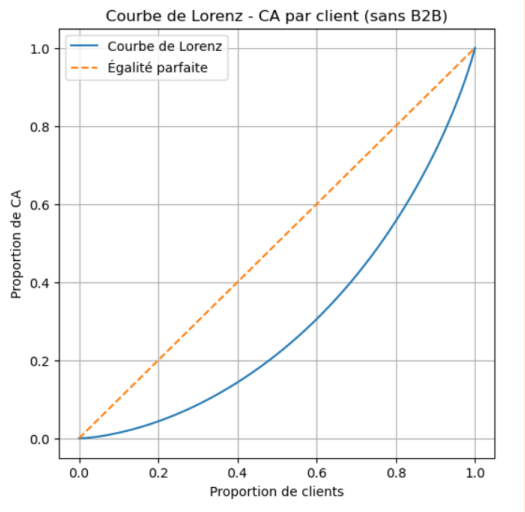


En isolant les 4 clients B2B, on peut calculer leur impact sur le CA global : ils représentent 7.4% du CA total.



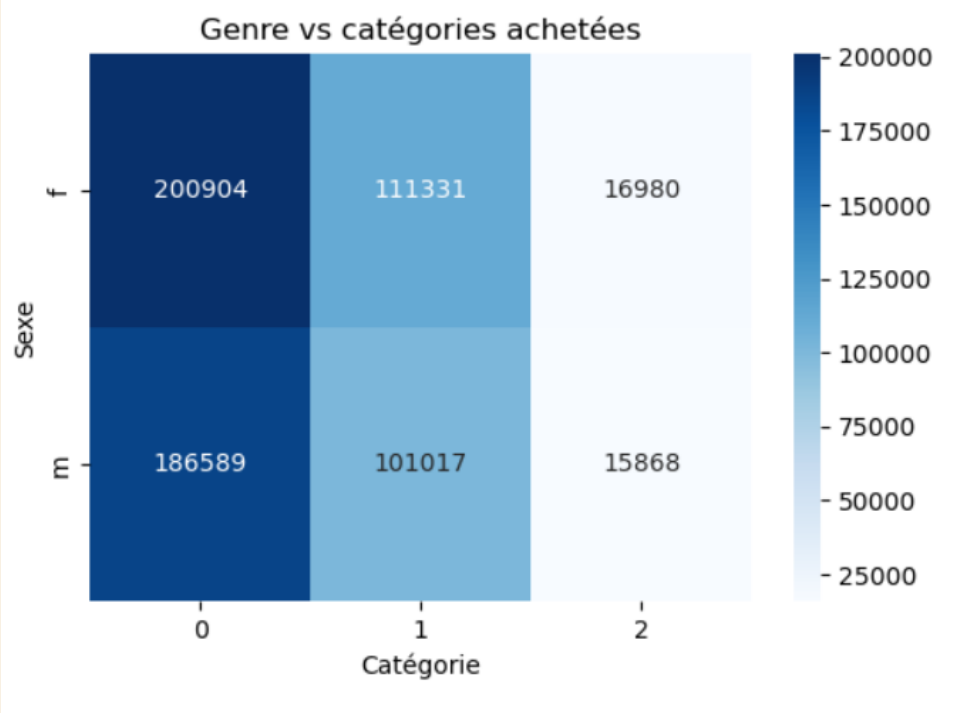


Cela se voit sur la courbe de Lorenz (fin du graphique à gauche). Tandis que si l'on les enlève, on aperçoit une courbe de Lorenz classique.



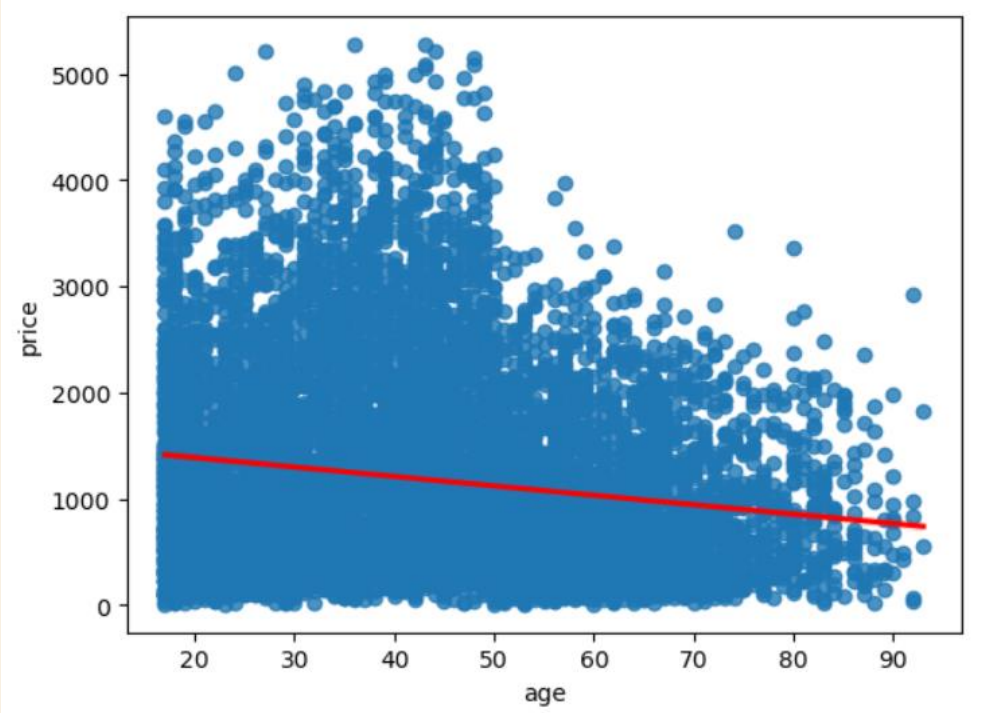
5. ANALYSE VIA DES TESTS STATISTIQUES

Genre et catégories achetées - test khi2



Genre et catégories : 2 variables qualitatives.
Relation significative entre le sexe des clients et les catégories de produits achetées ($p < 0,05$).

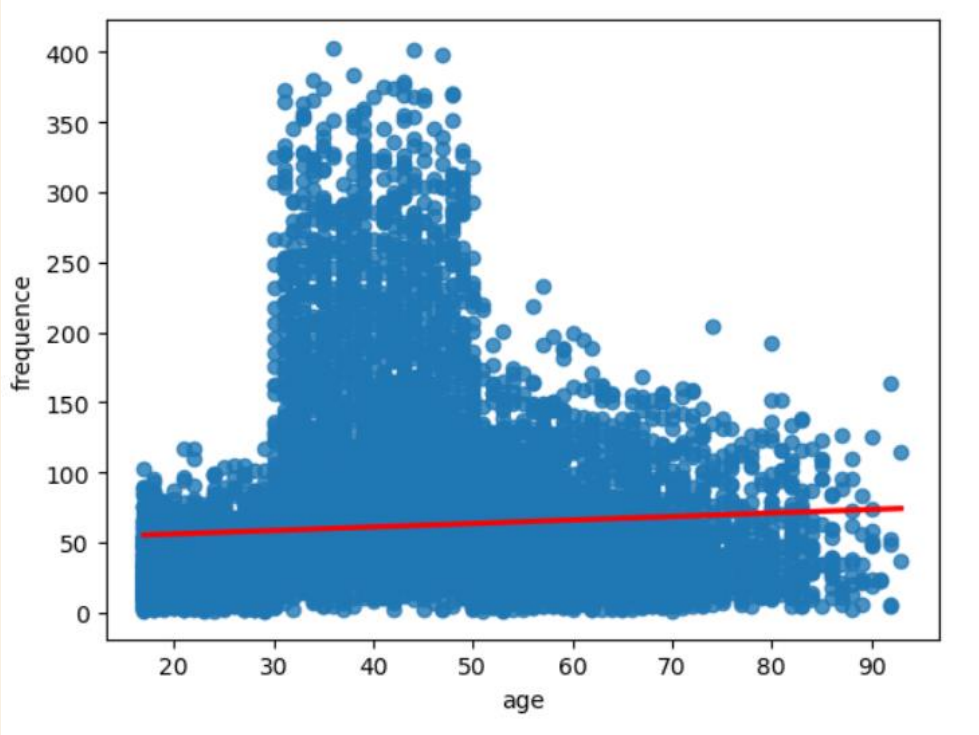
Âge et montant total des achats - test Pearson



Âge et montant total des achats : 2 variables quantitatives.
$p < 0.05$: relation entre l'âge et le montant des achats.
$r = -0.187$: La relation est négative.
Plus l'âge augmente, plus le montant total des achats tend à légèrement diminuer.

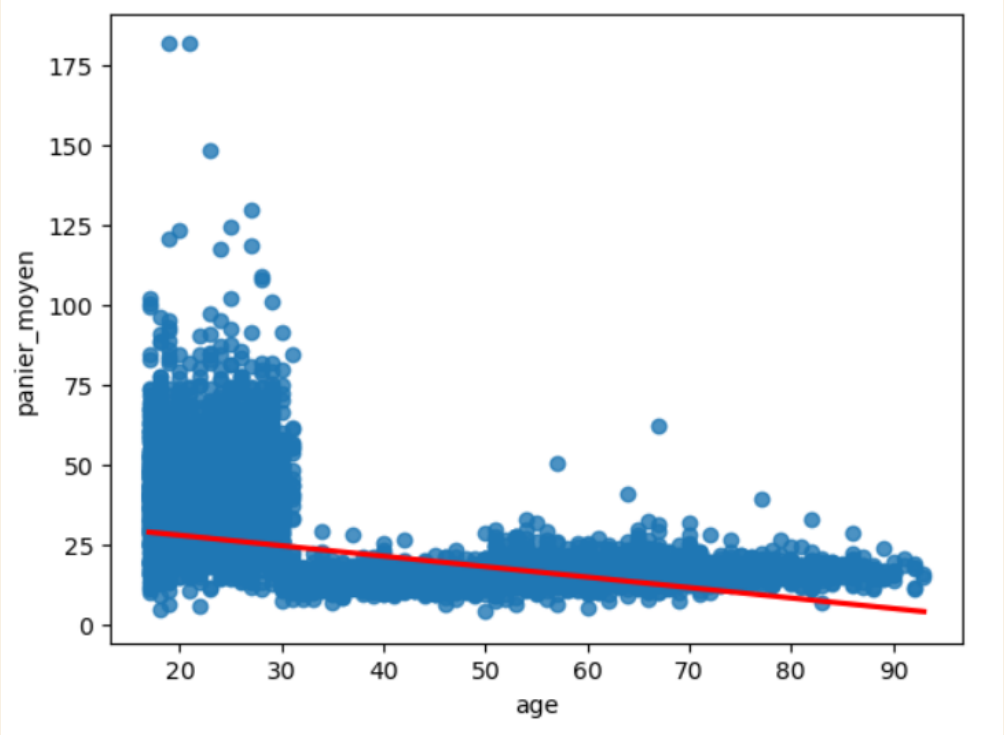
5. ANALYSE VIA DES TESTS STATISTIQUES

Âge et fréquence d’achat - test Spearman



Âge et fréquence d'achat : 2 variables quantitatives.
p < 0.05 : relation significative entre âge et fréquence d’achat.
Spearman rho = 0.130 : plus l’âge augmente, plus la fréquence d’achat tend à augmenter, augmentation légère.

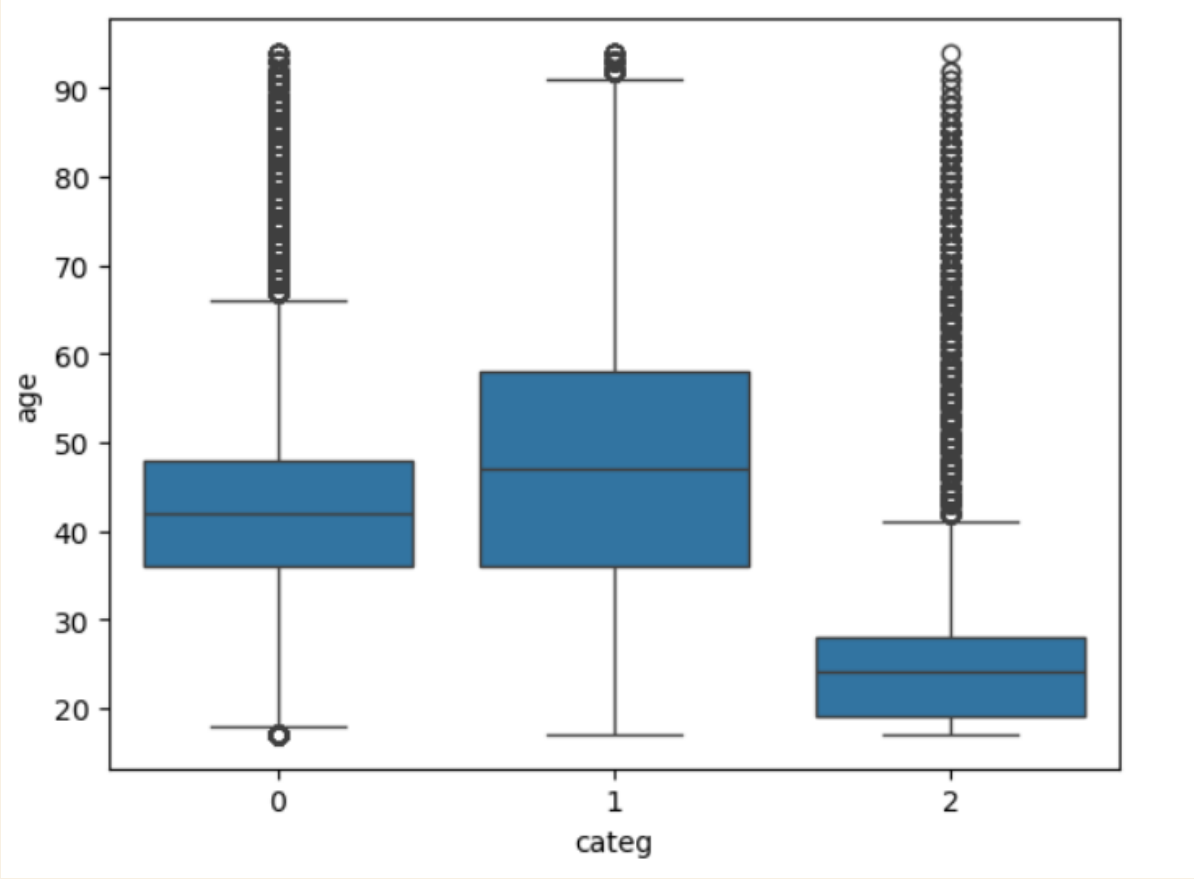
Âge et panier moyen - test Pearson



Âge et panier moyen : 2 variables quantitatives.
p < 0.05 : relation significative entre âge et panier moyen.
r = -0.513 : plus l’âge augmente, plus le panier moyen diminue.

5. ANALYSE VIA DES TESTS STATISTIQUES

Âge et catégories achetées - test ANOVA



Âge = valeur quantitative.
Catégorie = valeur qualitative.
On a trois catégories, donc plusieurs groupes.
On a donc besoin d'un test mixte,
tel que le **test ANOVA**.

$p < 0.05$: les âges ne sont pas les mêmes selon les catégories.

$F = 40424$: les catégories de produits sont très différenciées en âge.

ANALYSE DES RÉSULTATS

- Les comportements d'achat varient selon l'âge.
- Le sexe influence les catégories de produits achetées.
- Les jeunes dépensent davantage par achat.
- Tandis que les clients plus âgés achètent un peu plus souvent.

CONCLUSION

Les données ont permis :

- D'identifier les produits et catégories les plus performants,
- De mieux comprendre le comportement d'achat des clients,
- De valider plusieurs hypothèses grâce aux tests statistiques.

Perspectives :

- Adapter les actions marketing selon les profils de clients,
- Personnaliser les recommandations de produits,
- Mieux cibler la publicité en fonction de l'âge et des habitudes d'achat.

MERCI

Gabriel CAPELL

capell.gabriel@gmail.com